Manejo y limpieza de datos $_{FSC}$

Contents

Antes de empezar	1
El ecosistema <i>tidyverse</i>	1
Ejemplo motivacional: Gapminder foundation	3
Paquete dplyr: filter y select	4
$Tidy ext{ data}$	5
gather and spread -> pivot_longer and pivot_wider	8
Si los nombres de las columnas son numericos	10
Variables dentro de los nombres de columna	12
Varias observaciones por fila	14
separate y unite	15
Ejercicios: tidy/wide	17
Sumarizando data con $dplyr()$	19
summarize()	19
dot	20
group_by()	22
Ordenar data.frames: $arrange() top_n() \dots \dots \dots \dots \dots \dots \dots \dots$	22
Ejercicios: NCHS Data	23
Tidyverse conditionals	24
case_when	24
between	25
Limpieza de datos: el paquete janitor	2 5
tabyl better than table: adorn_() functions	25
Ejemplo 1: mtcars	26
Ejemplo 2: starwars	26
Ejemplo 3: Modelos de coches	28
Otras funciones del paquete janitor	28
$\operatorname{get_dupes}() \ldots \ldots \ldots \ldots \ldots$	28
$\operatorname{get_dupes}() \ldots \ldots \ldots \ldots \ldots$	29
$\operatorname{round_half_up}() \dots \dots$	29
factores	29

Antes de empezar...

Los materiales de esta clase han sido preparados utilizando dos libros que están disponibles bajo licencia OUP y que os invito a explorar:

 $Hands-on\ programming\ with\ R\ https://rstudio-education.github.io/hopr/$

Data Science with R https://rafalab.github.io/dsbook/

El ecosistema tidyverse

Se trata de una colección de paquetes de R diseñados por Hadley Wickham específicamente para data science. Todos los paquetes comparten la misma filosofia, diseño, gramática y estructura.



Figure 1: Tidyverse

Todos los paquetes de *tidyverse* pueden instalarse de una vez con:

```
#install.packages("tidyverse")
```

Ejemplo motivacional: Gapminder foundation

La organización Gapminder trata de desenmascarar falsos mitos acerca del estado del mundo en terminos de pobreza, desigualdad, etc a través del uso de datos. Utilizando el dataset gapminder del paquete dslabs trataremos de contestar a dos preguntas:

- 1. Es cierto que el mundo se divide en paises occidentales ricos y no-occidentales pobres?
- 2. Han aumentado las diferencias entre paises en los últimos 40 años?
- Descargamos los datos:

```
library(dslabs)
data(gapminder)
#si no tienes el paquete instalado
#gapminder=read.csv("DataSets/Gapminder.csv")
```

*Exploramos los datos:

```
View(gapminder)
head(gapminder)
```

```
##
                  country year infant_mortality life_expectancy fertility
## 1
                  Albania 1960
                                          115.40
                                                            62.87
                                                                        6.19
## 2
                  Algeria 1960
                                          148.20
                                                            47.50
                                                                        7.65
                                          208.00
                                                            35.98
                                                                        7.32
## 3
                   Angola 1960
                                                            62.97
## 4 Antigua and Barbuda 1960
                                              NA
                                                                        4.43
## 5
                                           59.87
                                                            65.39
                                                                        3.11
                Argentina 1960
## 6
                  Armenia 1960
                                              NA
                                                            66.86
                                                                        4.55
##
     population
                          gdp continent
                                                   region
## 1
        1636054
                           NA
                                  Europe Southern Europe
## 2
       11124892
                 13828152297
                                  Africa Northern Africa
## 3
        5270844
                                  Africa
                                           Middle Africa
                           NΑ
## 4
          54681
                           NA
                               Americas
                                               Caribbean
## 5
       20619075 108322326649
                               Americas
                                           South America
## 6
        1867396
                                    Asia
                                            Western Asia
```

```
str(gapminder)
```

```
'data.frame':
                  10545 obs. of 9 variables:
##
   $ country
                    : Factor w/ 185 levels "Albania", "Algeria", ...: 1 2 3 4 5 6 7 8 9 10 ...
##
   $ year
                           $ infant_mortality: num
                           115.4 148.2 208 NA 59.9 ...
##
   $ life_expectancy : num
                           62.9 47.5 36 63 65.4 ...
##
   $ fertility
                    : num
                           6.19 7.65 7.32 4.43 3.11 4.55 4.82 3.45 2.7 5.57 ...
##
   $ population
                           1636054 11124892 5270844 54681 20619075 ...
##
                           NA 1.38e+10 NA NA 1.08e+11 ...
   $ gdp
                    : num
##
   $ continent
                    : Factor w/ 5 levels "Africa", "Americas", ...: 4 1 1 2 2 3 2 5 4 3 ...
                    : Factor w/ 22 levels "Australia and New Zealand",..: 19 11 10 2 15 21 2 1 22 21
  $ region
```

- De las siguientes parejas, cual dirias que tuvo la mayor mortalidad infantil en 2015?
- ++ Sri Lanka or Turkey
- ++ Poland or South Korea
- ++ Malaysia or Russia

```
++ Pakistan or Vietnam
```

++ Thailand or South Africa

Ahora, trata de responderlo usando los datos por medio de los comandos filter y select

Paquete dplyr: filter y select

filter se encarga de hacer subsetting de un data.frame, tibble o matriz mientras que select selecciona las columnas. Como cualquier otra función tidyverse el primer argumento tiene que ser el objeto que se va a manipular. A continuacion con filter se da una condicion logica que devuelve TRUE or FALSE para cada fila. Para select es suficiente con dar el nombre de la columna pero tambien pueden proporcionarse funciones como starts_with(), ends_with() o contain(). Si se quiere quitar una columna basta con poner un "-" delante.

Por ejemplo, usando filter and select podemos quedarnos solo con la informacion de mortalidad infantil en cada pareja de paises en el año 2015:

```
library(dplyr)
gapminder %>%
  filter(year == 2015 & country %in% c("Sri Lanka", "Turkey")) %>%
  select(country, infant_mortality)
       country infant_mortality
## 1 Sri Lanka
                             8.4
## 2
        Turkey
                            11.6
gapminder %>%
  filter(year == 2015 & country %in% c("Poland", "South Korea")) %>%
  select(country, infant_mortality)
##
         country infant_mortality
## 1 South Korea
                               2.9
## 2
          Poland
                               4.5
gapminder %>%
  filter(year == 2015 & country %in% c("Malaysia", "Russia")) %>%
  select(country, infant_mortality)
##
      country infant mortality
                            6.0
## 1 Malaysia
## 2
       Russia
                            8.2
gapminder %>%
  filter(year == 2015 & country %in% c("Pakistan", "Vietnam")) %>%
  select(country, infant_mortality)
##
      country infant_mortality
## 1 Pakistan
                           65.8
## 2 Vietnam
                           17.3
gapminder %>%
  filter(year == 2015 & country %in% c("Thailand", "South Africa")) %>%
  select(country, infant_mortality)
##
          country infant_mortality
## 1 South Africa
                               33.6
## 2
         Thailand
                               10.5
```

Si queremos centrarnos en los paises de una cierta región para ver por ejemplo la media pero no nos acordamos del nombre exacto de la columna:

```
gp.reduced<-gapminder %>%
  filter(year == 2015 ) %>%
  select(country, starts_with("reg"), infant_mortality)
head(gp.reduced)
```

```
##
                                  region infant_mortality
                 country
## 1
                 Albania Southern Europe
                                                     12.5
## 2
                 Algeria Northern Africa
                                                     21.9
## 3
                  Angola
                          Middle Africa
                                                     96.0
## 4 Antigua and Barbuda
                               Caribbean
                                                      5.8
## 5
               Argentina
                           South America
                                                     11.1
## 6
                 Armenia
                           Western Asia
                                                     12.6
```

Tidy data

Los datos están en formato tidy si la información de una o varias columnas constituyen una clave única para cada dato, frente a los datos de tipo "wide" para los que dicha clave viene dada por los nombres o identificadores de filas y columnas, haciendo complicado tener claves constituidas por mas de tres campos.

gapminder es un data frame tidy: para cada pais y año tenemos información de varios indicadores como mortalidad infantil, fertilidad, esperanza de vida, etc.

Fácilmente, gracias a que los datos están en formato tidy podemos usar el paquete ggplot2 para comparar la evolucion de la fertilidad y la esperanza de vida en Europa y Asia y así responder a las preguntas que teníamos:

```
library(ggplot2)
years <- c(1962, 1980, 1990, 2000, 2012)
continents <- c("Europe", "Asia")
gapminder %>%
  filter(year %in% years & continent %in% continents) %>%
  ggplot(aes(fertility, life_expectancy, col = continent)) +
  geom_point() +
  facet_wrap(~year)
```

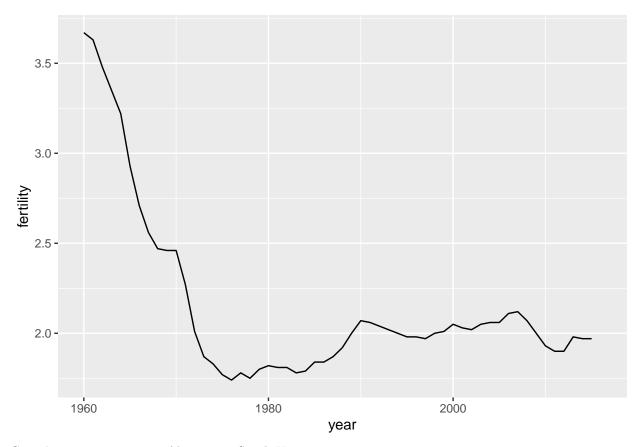


Viendo este plot parece que las diferencias entre Asia y Europa han ido desapareciendo con el paso de los años.

Centrémonos ahora sólo en el indicador de fertilidad de un pais, USA:

```
gapminder %>%
  filter(country == "United States") %>%
  ggplot(aes(year,fertility)) +
  geom_line()
```

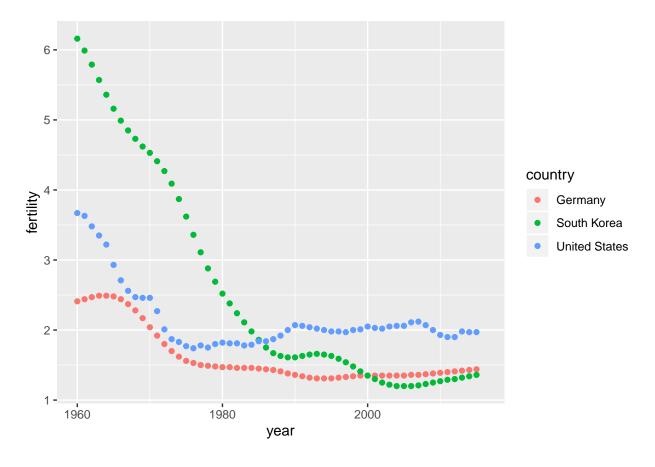
Warning: Removed 1 rows containing missing values (geom_path).



Centrémonos en comparar Alemania y South Korea

```
data("gapminder")
tidy_data <- gapminder %>%
  filter(country %in%
         c("South Korea", "Germany", "United States")) %>%
  select(country, year, fertility)
head(tidy_data)
##
           country year fertility
## 1
           Germany 1960
                              2.41
## 2
       South Korea 1960
                              6.16
## 3 United States 1960
                              3.67
                              2.44
## 4
           Germany 1961
## 5
                              5.99
       South Korea 1961
## 6 United States 1961
                             3.63
tidy_data %>%
  ggplot(aes(year, fertility, color = country)) +
  geom_point()
```

Warning: Removed 3 rows containing missing values (geom_point).



gather and spread -> pivot_longer and pivot_wider

Todo esto ha sido posible porque gapminder contiene la información en un formato tidy. Irizarry y sus colegas han hecho un gran esfuerzo para poder tener los datos limpios y en este formato. Cómo podemos transformar datos wide en datos tidy? Utilizando la función gather o mejor aun, su sustituta pivot_longer()

Primero leemos los datos en formato tibble.

```
path <- system.file("extdata", package="dslabs")</pre>
filename <- file.path(path, "fertility-two-countries-example.csv")
wide_data <- read_csv(filename)</pre>
## Parsed with column specification:
## cols(
##
     .default = col_double(),
##
     country = col_character()
## )
## See spec(...) for full column specifications.
wide_data
## # A tibble: 2 x 57
     country `1960` `1961` `1962` `1963` `1964` `1965` `1966` `1967` `1968`
##
                      <dbl>
                                    <dbl>
                                                   <dbl>
                                                           <dbl>
##
     <chr>>
              <dbl>
                             <dbl>
                                            <dbl>
                                                                  <dbl>
                                                                          <dbl>
               2.41
## 1 Germany
                       2.44
                              2.47
                                      2.49
                                             2.49
                                                    2.48
                                                            2.44
                                                                   2.37
                                                                          2.28
               6.16
                       5.99
                              5.79
                                     5.57
                                             5.36
                                                    5.16
                                                            4.99
                                                                   4.85
                                                                          4.73
## 2 South ~
## # ... with 47 more variables: `1969` <dbl>, `1970` <dbl>, `1971` <dbl>,
     `1972` <dbl>, `1973` <dbl>, `1974` <dbl>, `1975` <dbl>, `1976` <dbl>,
```

```
## #
       `1977` <dbl>, `1978` <dbl>, `1979` <dbl>, `1980` <dbl>, `1981` <dbl>,
## #
       `1982` <dbl>, `1983` <dbl>, `1984` <dbl>, `1985` <dbl>, `1986` <dbl>,
## #
       `1987` <dbl>, `1988` <dbl>, `1989` <dbl>, `1990` <dbl>, `1991` <dbl>,
       `1992` <dbl>, `1993` <dbl>, `1994` <dbl>, `1995` <dbl>, `1996` <dbl>,
## #
       `1997` <dbl>, `1998` <dbl>, `1999` <dbl>, `2000` <dbl>, `2001` <dbl>,
## #
## #
       `2002` <dbl>, `2003` <dbl>, `2004` <dbl>, `2005` <dbl>, `2006` <dbl>,
       '2007' <dbl>, '2008' <dbl>, '2009' <dbl>, '2010' <dbl>, '2011' <dbl>,
       `2012` <dbl>, `2013` <dbl>, `2014` <dbl>, `2015` <dbl>
## #
#como ejemplo: seleccionamos las primeras 9 columnas por nombre
select(wide_data, country, `1960`: `1967`)
## # A tibble: 2 x 9
     country
                  `1960` `1961` `1962` `1963` `1964` `1965` `1966`
##
     <chr>>
                   <dbl>
                          <dbl>
                                 <dbl>
                                         <dbl>
                                                <dbl>
                                                        <dbl>
                                                               <dbl>
                                                                       <dbl>
## 1 Germany
                    2.41
                           2.44
                                   2.47
                                          2.49
                                                 2.49
                                                         2.48
                                                                2.44
                                                                        2.37
                    6.16
                           5.99
                                   5.79
                                          5.57
                                                 5.36
                                                                4.99
                                                                        4.85
## 2 South Korea
                                                         5.16
Las funciones gather y pivot_longer() van a "normalizar" los datos en las columnas que le digamos (1960:2015)
preservando la información del resto de columnas de la matriz. Los primeros valores que le damos es el
nombre del "key" y el nombre para el "value"
new_tidy_data <- wide_data %>%
  gather(year, fertility, -country)
new_tidy_data
## # A tibble: 112 x 3
##
      country
                  year
                         fertility
##
      <chr>
                   <chr>>
                             <dbl>
##
    1 Germany
                   1960
                              2.41
##
  2 South Korea 1960
                              6.16
  3 Germany
                              2.44
                   1961
                              5.99
## 4 South Korea 1961
##
   5 Germany
                   1962
                              2.47
## 6 South Korea 1962
                              5.79
## 7 Germany
                   1963
                              2.49
                              5.57
## 8 South Korea 1963
## 9 Germany
                   1964
                              2.49
## 10 South Korea 1964
                              5.36
## # ... with 102 more rows
class(new_tidy_data$year)
## [1] "character"
gather toma el tipo de las variables que recoje, y como son caracteres no les cambia el tipo a no ser que
digamos:
new_tidy_data <- wide_data %>%
  gather(year, fertility, -country, convert = TRUE)
class(new_tidy_data$year)
## [1] "integer"
pivot_longer() es mas intuitiva:
new_tidy_data <- wide_data %>%
  pivot_longer(-country,names_to = "year",values_to = "fertility")
class(new_tidy_data$year)
```

[1] "character"

A veces se necesita volver de tidy data a wide data usando spread o pivot_wider()

```
new wide data <- new tidy data %>%
  spread(year, fertility)
select(new_wide_data, country, `1960`: `1967`)
## # A tibble: 2 x 9
     country
                  `1960` `1961` `1962` `1963` `1964` `1965` `1966`
##
     <chr>>
                                                                <dbl>
                   <dbl>
                          <dbl>
                                  <dbl>
                                         <dbl>
                                                 <dbl>
                                                        <dbl>
                                                                        <dbl>
## 1 Germany
                    2.41
                            2.44
                                   2.47
                                           2.49
                                                  2.49
                                                          2.48
                                                                 2.44
                                                                         2.37
## 2 South Korea
                    6.16
                            5.99
                                   5.79
                                           5.57
                                                  5.36
                                                          5.16
                                                                 4.99
                                                                         4.85
new_wide_data <- new_tidy_data %>%
  pivot_wider(names_from=year, values_from=fertility)
select(new_wide_data, country, `1960`:`1967`)
## # A tibble: 2 x 9
                  `1960` `1961` `1962` `1963` `1964` `1965` `1966`
     country
##
     <chr>>
                   <dbl>
                          <dbl>
                                  <dbl>
                                         <dbl>
                                                 <dbl>
                                                        <dbl>
                                                                <dbl>
                                                                        <dbl>
## 1 Germany
                    2.41
                            2.44
                                   2.47
                                           2.49
                                                  2.49
                                                          2.48
                                                                 2.44
                                                                         2.37
## 2 South Korea
                    6.16
                            5.99
                                   5.79
                                           5.57
                                                  5.36
                                                          5.16
                                                                 4.99
                                                                         4.85
```

Si los nombres de las columnas son numericos

billboard

```
## # A tibble: 317 x 79
                                          wk2
                                                wk3
##
      artist track date.entered
                                                             wk5
                                                                   wk6
                                                                         wk7
                                   wk1
                                                      wk4
##
      <chr> <chr> <date>
                                 <dbl> <dbl>
                                              <dbl>
                                                    <dbl>
                                                          <dbl>
                                                                 <dbl> <dbl>
    1 2 Pac Baby~ 2000-02-26
                                                 72
                                                       77
##
                                    87
                                           82
                                                             87
                                                                    94
    2 2Ge+h~ The ~ 2000-09-02
                                    91
                                           87
                                                 92
                                                       NA
                                                             NA
                                                                    NA
                                                                          NA
##
    3 3 Doo~ Kryp~ 2000-04-08
                                    81
                                           70
                                                 68
                                                       67
                                                             66
                                                                    57
                                                                          54
   4 3 Doo~ Loser 2000-10-21
                                    76
                                           76
                                                 72
                                                             67
                                                                    65
  5 504 B~ Wobb~ 2000-04-15
##
                                    57
                                           34
                                                 25
                                                       17
                                                             17
                                                                    31
                                                                          36
    6 98^0
            Give~ 2000-08-19
                                    51
                                           39
                                                 34
                                                       26
                                                              26
                                                                    19
                                                                           2
  7 A*Tee~ Danc~ 2000-07-08
                                    97
                                           97
                                                 96
                                                       95
                                                             100
                                                                    NA
                                                                          NA
    8 Aaliy~ I Do~ 2000-01-29
                                    84
                                           62
                                                 51
                                                       41
                                                             38
                                                                    35
                                                                          35
    9 Aaliy~ Try ~ 2000-03-18
##
                                    59
                                           53
                                                 38
                                                       28
                                                             21
                                                                    18
                                                                          16
## 10 Adams~ Open~ 2000-08-26
                                    76
                                           76
                                                 74
                                                       69
                                                             68
                                                                    67
## # ... with 307 more rows, and 69 more variables: wk8 <dbl>, wk9 <dbl>,
       wk10 <dbl>, wk11 <dbl>, wk12 <dbl>, wk13 <dbl>, wk14 <dbl>,
## #
## #
       wk15 <dbl>, wk16 <dbl>, wk17 <dbl>, wk18 <dbl>, wk19 <dbl>,
## #
       wk20 <dbl>, wk21 <dbl>, wk22 <dbl>, wk23 <dbl>, wk24 <dbl>,
## #
       wk25 <dbl>, wk26 <dbl>, wk27 <dbl>, wk28 <dbl>, wk29 <dbl>,
       wk30 <dbl>, wk31 <dbl>, wk32 <dbl>, wk33 <dbl>, wk34 <dbl>,
## #
## #
       wk35 <dbl>, wk36 <dbl>, wk37 <dbl>, wk38 <dbl>, wk39 <dbl>,
## #
       wk40 <dbl>, wk41 <dbl>, wk42 <dbl>, wk43 <dbl>, wk44 <dbl>,
       wk45 <dbl>, wk46 <dbl>, wk47 <dbl>, wk48 <dbl>, wk49 <dbl>,
       wk50 <dbl>, wk51 <dbl>, wk52 <dbl>, wk53 <dbl>, wk54 <dbl>,
## #
       wk55 <dbl>, wk56 <dbl>, wk57 <dbl>, wk58 <dbl>, wk59 <dbl>,
## #
## #
       wk60 <dbl>, wk61 <dbl>, wk62 <dbl>, wk63 <dbl>, wk64 <dbl>,
       wk65 <dbl>, wk66 <lgl>, wk67 <lgl>, wk68 <lgl>, wk69 <lgl>,
       wk70 <lgl>, wk71 <lgl>, wk72 <lgl>, wk73 <lgl>, wk74 <lgl>,
## #
## #
       wk75 <lgl>, wk76 <lgl>
```

```
billboard %>%
  pivot_longer(
    cols = starts_with("wk"),
    names to = "week",
    values_to = "rank",
    values_drop_na = TRUE
 )
## # A tibble: 5,307 x 5
##
      artist track
                                       date.entered week
                                                            rank
##
      <chr>
              <chr>
                                        <date>
                                                     <chr> <dbl>
##
   1 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk1
                                                              87
   2 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk2
                                                              82
   3 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk3
                                                              72
##
   4 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk4
                                                              77
##
   5 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk5
                                                              87
   6 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                              94
                                                     wk6
   7 2 Pac
              Baby Don't Cry (Keep... 2000-02-26
                                                     wk7
                                                              99
   8 2Ge+her The Hardest Part Of ... 2000-09-02
                                                     wk1
                                                              91
## 9 2Ge+her The Hardest Part Of ... 2000-09-02
                                                              87
                                                     wk2
## 10 2Ge+her The Hardest Part Of ... 2000-09-02
                                                     wk3
                                                              92
## # ... with 5,297 more rows
Convertimos el objeto "wide" en "tidy":
billboard
## # A tibble: 317 x 79
##
      artist track date.entered
                                         wk2
                                                wk3
                                                            wk5
                                                                  wk6
                                                                         wk7
                                   wk1
                                                      wk4
```

```
<chr> <chr> <date>
                                 <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <
   1 2 Pac Baby~ 2000-02-26
##
                                     87
                                           82
                                                 72
                                                        77
                                                              87
                                                                    94
                                                                           99
    2 \text{ 2Ge+h-} The - 2000-09-02
                                     91
                                           87
                                                 92
                                                       NA
                                                              NA
                                                                    NA
                                                                           NA
   3 3 Doo~ Kryp~ 2000-04-08
                                     81
                                           70
                                                 68
                                                        67
                                                              66
                                                                    57
                                                                           54
   4 3 Doo~ Loser 2000-10-21
                                     76
                                           76
                                                 72
                                                        69
                                                              67
                                                                    65
                                                                           55
    5 504 B~ Wobb~ 2000-04-15
##
                                     57
                                           34
                                                 25
                                                        17
                                                              17
                                                                    31
                                                                           36
    6 98^0
            Give~ 2000-08-19
                                     51
                                           39
                                                 34
                                                        26
                                                              26
                                                                    19
                                                                           2
   7 A*Tee~ Danc~ 2000-07-08
                                     97
                                           97
                                                 96
                                                             100
                                                                           NA
    8 Aaliy~ I Do~ 2000-01-29
                                                              38
                                                                           35
                                     84
                                           62
                                                 51
                                                        41
                                                                    35
   9 Aaliy~ Try ~ 2000-03-18
                                     59
                                           53
                                                 38
                                                        28
                                                              21
                                                                    18
                                                                           16
                                                       69
## 10 Adams~ Open~ 2000-08-26
                                     76
                                           76
                                                 74
                                                              68
                                                                    67
## # ... with 307 more rows, and 69 more variables: wk8 <dbl>, wk9 <dbl>,
       wk10 <dbl>, wk11 <dbl>, wk12 <dbl>, wk13 <dbl>, wk14 <dbl>,
## #
       wk15 <dbl>, wk16 <dbl>, wk17 <dbl>, wk18 <dbl>, wk19 <dbl>,
## #
       wk20 <dbl>, wk21 <dbl>, wk22 <dbl>, wk23 <dbl>, wk24 <dbl>,
       wk25 <dbl>, wk26 <dbl>, wk27 <dbl>, wk28 <dbl>, wk29 <dbl>,
       wk30 <dbl>, wk31 <dbl>, wk32 <dbl>, wk33 <dbl>, wk34 <dbl>,
## #
## #
       wk35 <dbl>, wk36 <dbl>, wk37 <dbl>, wk38 <dbl>, wk39 <dbl>,
## #
       wk40 <dbl>, wk41 <dbl>, wk42 <dbl>, wk43 <dbl>, wk44 <dbl>,
       wk45 <dbl>, wk46 <dbl>, wk47 <dbl>, wk48 <dbl>, wk49 <dbl>,
## #
       wk50 <dbl>, wk51 <dbl>, wk52 <dbl>, wk53 <dbl>, wk54 <dbl>,
## #
       wk55 <dbl>, wk56 <dbl>, wk57 <dbl>, wk58 <dbl>, wk59 <dbl>,
       wk60 <dbl>, wk61 <dbl>, wk62 <dbl>, wk63 <dbl>, wk64 <dbl>,
## #
## #
       wk65 <dbl>, wk66 <lgl>, wk67 <lgl>, wk68 <lgl>, wk69 <lgl>,
## #
       wk70 <lgl>, wk71 <lgl>, wk72 <lgl>, wk73 <lgl>, wk74 <lgl>,
## #
       wk75 <lgl>, wk76 <lgl>
```

```
billboard %>%
  pivot_longer(
   cols = starts_with("wk"),
   names to = "week",
   values_to = "rank",
   values_drop_na = TRUE
 )
## # A tibble: 5,307 x 5
##
     artist track
                                      date.entered week
                                                         rank
##
      <chr>
             <chr>
                                      <date>
                                                 <chr> <dbl>
##
  1 2 Pac Baby Don't Cry (Keep... 2000-02-26
                                                  wk1
                                                            87
## 2 2 Pac Baby Don't Cry (Keep... 2000-02-26
                                                   wk2
## 3 2 Pac Baby Don't Cry (Keep... 2000-02-26
                                                   wk3
                                                            72
## 4 2 Pac Baby Don't Cry (Keep... 2000-02-26
                                                   wk4
                                                            77
                                                   wk5
                                                            87
## 5 2 Pac Baby Don't Cry (Keep... 2000-02-26
## 6 2 Pac
             Baby Don't Cry (Keep... 2000-02-26
                                                   wk6
                                                            94
## 7 2 Pac
             Baby Don't Cry (Keep... 2000-02-26
                                                   wk7
                                                            99
## 8 2Ge+her The Hardest Part Of ... 2000-09-02
                                                   wk1
                                                            91
## 9 2Ge+her The Hardest Part Of ... 2000-09-02
                                                            87
                                                   wk2
## 10 2Ge+her The Hardest Part Of ... 2000-09-02
                                                   wk3
                                                            92
## # ... with 5,297 more rows
Ahora queremos convertir la variable semana en numerica
billboard %>%
 pivot longer(
   cols = starts_with("wk"),
   names_to = "week",
   names_prefix = "wk",
   names ptypes = list(week = integer()),
   values to = "rank",
   values_drop_na = TRUE,
 )
## # A tibble: 5,307 x 5
##
     artist track
                                      date.entered week rank
##
      <chr>
             <chr>>
                                                  <int> <dbl>
  1 2 Pac Baby Don't Cry (Keep... 2000-02-26
##
                                                       1
                                                            87
  2 2 Pac Baby Don't Cry (Keep... 2000-02-26
                                                            82
             Baby Don't Cry (Keep... 2000-02-26
## 3 2 Pac
                                                       3
                                                            72
## 4 2 Pac
             Baby Don't Cry (Keep... 2000-02-26
                                                       4
                                                           77
                                                       5
## 5 2 Pac
             Baby Don't Cry (Keep... 2000-02-26
                                                            87
## 6 2 Pac
             Baby Don't Cry (Keep... 2000-02-26
                                                       6
                                                            94
             Baby Don't Cry (Keep... 2000-02-26
                                                       7
## 7 2 Pac
                                                           99
## 8 2Ge+her The Hardest Part Of ... 2000-09-02
                                                       1
                                                            91
## 9 2Ge+her The Hardest Part Of ... 2000-09-02
                                                       2
                                                            87
## 10 2Ge+her The Hardest Part Of ... 2000-09-02
                                                            92
## # ... with 5,297 more rows
```

Variables dentro de los nombres de columna

who

```
## # A tibble: 7,240 x 60
## country iso2 iso3 year new_sp_m014 new_sp_m1524 new_sp_m2534
```

```
##
      <chr>
              <chr> <chr> <int>
                                       <int>
                                                    <int>
                                                                  <int>
##
   1 Afghan~ AF
                    AFG
                            1980
                                          NA
                                                       NA
                                                                     NA
    2 Afghan~ AF
                    AFG
                           1981
                                          NA
                                                       NA
                                                                     NA
##
  3 Afghan~ AF
                    AFG
                           1982
                                                                     NA
                                          NA
                                                       NA
##
    4 Afghan~ AF
                    AFG
                           1983
                                          NA
                                                       NA
                                                                     NA
##
  5 Afghan~ AF
                    AFG
                           1984
                                          NA
                                                                     NA
                                                       NA
  6 Afghan~ AF
                    AFG
                           1985
                                          NA
                                                       NA
                                                                     NA
   7 Afghan~ AF
##
                    AFG
                           1986
                                          NA
                                                       NA
                                                                     NA
##
    8 Afghan~ AF
                    AFG
                           1987
                                          NA
                                                       NA
                                                                     NA
##
   9 Afghan~ AF
                    AFG
                           1988
                                          NA
                                                       NA
                                                                     NA
## 10 Afghan~ AF
                    AFG
                           1989
                                          NA
                                                       NA
                                                                     NA
## # ... with 7,230 more rows, and 53 more variables: new_sp_m3544 <int>,
       new_sp_m4554 <int>, new_sp_m5564 <int>, new_sp_m65 <int>,
       new_sp_f014 <int>, new_sp_f1524 <int>, new_sp_f2534 <int>,
## #
## #
       new_sp_f3544 <int>, new_sp_f4554 <int>, new_sp_f5564 <int>,
## #
       new_sp_f65 <int>, new_sn_m014 <int>, new_sn_m1524 <int>,
## #
       new_sn_m2534 <int>, new_sn_m3544 <int>, new_sn_m4554 <int>,
## #
       new sn m5564 <int>, new sn m65 <int>, new sn f014 <int>,
## #
       new_sn_f1524 <int>, new_sn_f2534 <int>, new_sn_f3544 <int>,
## #
       new_sn_f4554 <int>, new_sn_f5564 <int>, new_sn_f65 <int>,
## #
       new_ep_m014 <int>, new_ep_m1524 <int>, new_ep_m2534 <int>,
## #
       new_ep_m3544 <int>, new_ep_m4554 <int>, new_ep_m5564 <int>,
## #
       new_ep_m65 <int>, new_ep_f014 <int>, new_ep_f1524 <int>,
       new_ep_f2534 <int>, new_ep_f3544 <int>, new_ep_f4554 <int>,
## #
## #
       new_ep_f5564 <int>, new_ep_f65 <int>, newrel_m014 <int>,
## #
       newrel_m1524 <int>, newrel_m2534 <int>, newrel_m3544 <int>,
## #
       newrel_m4554 <int>, newrel_m5564 <int>, newrel_m65 <int>,
## #
       newrel_f014 <int>, newrel_f1524 <int>, newrel_f2534 <int>,
## #
       newrel_f3544 <int>, newrel_f4554 <int>, newrel_f5564 <int>,
## #
       newrel_f65 <int>
who %>%
pivot_longer(
  cols = new_sp_m014:newrel_f65,
  names_to = c("diagnosis", "gender", "age"),
  names_pattern = "new_?(.*)_(.)(.*)",
  values_to = "count"
)
## # A tibble: 405,440 x 8
      country
                  iso2 iso3
                               year diagnosis gender age
                                                            count
##
      <chr>
                  <chr> <chr> <int> <chr>
                                               <chr> <chr> <int>
##
  1 Afghanistan AF
                        AFG
                                1980 sp
                                                      014
                                                                NA
                                               m
## 2 Afghanistan AF
                        AFG
                                1980 sp
                                                      1524
                                                                NA
                                               m
## 3 Afghanistan AF
                                1980 sp
                                                      2534
                        AFG
                                               m
                                                                NΑ
## 4 Afghanistan AF
                        AFG
                                1980 sp
                                                      3544
                                                                NA
                                               m
## 5 Afghanistan AF
                        AFG
                                                                NΑ
                                1980 sp
                                                      4554
                                               m
## 6 Afghanistan AF
                        AFG
                                1980 sp
                                               m
                                                      5564
                                                                NA
                        AFG
## 7 Afghanistan AF
                                1980 sp
                                                      65
                                                                NA
                                               m
## 8 Afghanistan AF
                        AFG
                                1980 sp
                                               f
                                                      014
                                                                NA
## 9 Afghanistan AF
                        AFG
                                1980 sp
                                               f
                                                      1524
                                                                NA
## 10 Afghanistan AF
                                               f
                                                      2534
                        AFG
                                1980 sp
                                                                NA
## # ... with 405,430 more rows
```

```
who %>%
pivot_longer(
 cols = new_sp_m014:newrel_f65,
 names_to = c("diagnosis", "gender", "age"),
 names_pattern = "new_?(.*)_(.)(.*)",
 names_ptypes = list(
   gender = factor(levels = c("f", "m")),
   age = factor(
     levels = c("014", "1524", "2534", "3544", "4554", "5564", "65"),
     ordered = TRUE
   )
 ),
 values_to = "count"
## # A tibble: 405,440 x 8
     country
                 iso2 iso3
                              year diagnosis gender age
##
     <chr>
                 <chr> <chr> <int> <chr>
                                             <fct> <ord> <int>
## 1 Afghanistan AF
                       AFG
                              1980 sp
                                             m
                                                    014
                                                             NA
## 2 Afghanistan AF
                       AFG
                                                    1524
                                                             NA
                              1980 sp
                                             m
## 3 Afghanistan AF
                       AFG
                              1980 sp
                                                    2534
                                                             NA
                                             m
## 4 Afghanistan AF
                       AFG
                              1980 sp
                                                    3544
                                                             NA
                                             m
## 5 Afghanistan AF
                       AFG
                                                   4554
                                                             NA
                              1980 sp
                                             m
## 6 Afghanistan AF
                       AFG
                              1980 sp
                                           m
                                                    5564
                                                             NA
## 7 Afghanistan AF
                       AFG
                              1980 sp
                                           m
                                                    65
                                                             NA
## 8 Afghanistan AF
                       AFG
                                             f
                                                    014
                                                             NA
                              1980 sp
## 9 Afghanistan AF
                       AFG
                              1980 sp
                                             f
                                                    1524
                                                             NA
                                             f
                                                    2534
                                                             NA
## 10 Afghanistan AF
                       AFG
                              1980 sp
## # ... with 405,430 more rows
```

Varias observaciones por fila

```
View(anscombe)
anscombe %>%
pivot_longer(everything(),
   names_to = c(".value", "set"),
   names_pattern = "(.)(.)"
)
```

```
## # A tibble: 44 x 3
##
     set x
     <chr> <dbl> <dbl>
            10 8.04
## 11
## 2 2
             10 9.14
## 3 3
            10 7.46
## 4 4
             8 6.58
## 5 1
             8 6.95
## 6 2
            8 8.14
## 7 3
             8 6.77
## 8 4
             8 5.76
             13 7.58
## 9 1
## 10 2
             13 8.74
## # ... with 34 more rows
```

separate y unite

Lo que hemos hecho hasta ahora es relativamente sencillo comparado con lo que solemos necesitar.¿Qué sucede si el nombre de las columnas que queremos "gather" no son muy claros como para usarlos como clave?

```
path <- system.file("extdata", package = "dslabs")</pre>
filename <- file.path(path, "life-expectancy-and-fertility-two-countries-example.csv")</pre>
raw_dat <- read_csv(filename)</pre>
## Parsed with column specification:
## cols(
##
     .default = col_double(),
     country = col_character()
## )
## See spec(...) for full column specifications.
select(raw_dat,1:5)
## # A tibble: 2 x 5
     country `1960_fertility` `1960_life_expe~ `1961_fertility`
##
##
     <chr>>
                         <dbl>
                                          <dbl>
                         2.41
                                           69.3
                                                             2.44
## 1 Germany
## 2 South ~
                         6.16
                                           53.0
                                                             5.99
## # ... with 1 more variable: `1961_life_expectancy` <dbl>
# lo transformamos en data tidy
dat <- raw_dat %>% gather(key, value, -country)
head(dat)
## # A tibble: 6 x 3
     country
                                       value
                 kev
##
     <chr>>
                                       <dbl>
                 <chr>
## 1 Germany
                 1960_fertility
                                        2.41
## 2 South Korea 1960_fertility
                                        6.16
## 3 Germany
                 1960_life_expectancy 69.3
## 4 South Korea 1960 life expectancy 53.0
## 5 Germany
                 1961_fertility
## 6 South Korea 1961_fertility
                                        5.99
# pero tenemos dos observaciones (año&variable) en cada fila
head(dat %>% separate(key, c("year", "variable_name"), "_"))
## Warning: Expected 2 pieces. Additional pieces discarded in 112 rows [3, 4,
## 7, 8, 11, 12, 15, 16, 19, 20, 23, 24, 27, 28, 31, 32, 35, 36, 39, 40, ...].
## # A tibble: 6 x 4
##
                 year variable_name value
     country
##
     <chr>>
                 <chr> <chr>
                                      <dbl>
                                       2.41
## 1 Germany
                 1960 fertility
## 2 South Korea 1960 fertility
                                       6.16
## 3 Germany
                 1960 life
                                      69.3
## 4 South Korea 1960 life
                                      53.0
## 5 Germany
                 1961 fertility
                                       2.44
## 6 South Korea 1961 fertility
                                       5.99
#"_" es el separador por defecto y por tanto no hace falta
head(dat %>% separate(key, c("year", "variable_name")))
```

```
## Warning: Expected 2 pieces. Additional pieces discarded in 112 rows [3, 4,
## 7, 8, 11, 12, 15, 16, 19, 20, 23, 24, 27, 28, 31, 32, 35, 36, 39, 40, ...].
## # A tibble: 6 x 4
##
     country
                year variable_name value
##
     <chr>>
                 <chr> <chr>
                                     <dbl>
## 1 Germany
                1960 fertility
                                     2.41
## 2 South Korea 1960 fertility
                                     6.16
## 3 Germany
                 1960 life
                                     69.3
                                    53.0
## 4 South Korea 1960 life
## 5 Germany
               1961 fertility
                                    2.44
## 6 South Korea 1961 fertility
                                     5.99
head(dat %>% separate(key, c("year", "first_variable_name", "second_variable_name"),
                     fill = "right"))
## # A tibble: 6 x 5
                year first_variable_name second_variable_name value
     country
##
     <chr>>
                 <chr> <chr>
                                          <chr>>
                                                                <dbl>
## 1 Germany
                 1960 fertility
                                           <NA>
                                                                 2.41
## 2 South Korea 1960 fertility
                                          <NA>
                                                                6.16
                 1960 life
                                                                69.3
## 3 Germany
                                          expectancy
## 4 South Korea 1960 life
                                                                53.0
                                          expectancy
                 1961 fertility
                                                                2.44
## 5 Germany
                                           <NA>
## 6 South Korea 1961 fertility
                                          <NA>
                                                                5.99
head(dat %>% separate(key, c("year", "variable_name"), extra = "merge"))
## # A tibble: 6 x 4
##
                year variable_name
     country
                                      value
     <chr>
                <chr> <chr>
                                       <dbl>
## 1 Germany
               1960 fertility
                                       2.41
## 2 South Korea 1960 fertility
                                       6.16
## 3 Germany
                1960 life_expectancy 69.3
## 4 South Korea 1960 life_expectancy 53.0
## 5 Germany 1961 fertility
                                       2.44
## 6 South Korea 1961 fertility
                                       5.99
#pero queremos crear una columna para cada variable
dat %>%
  separate(key, c("year", "variable_name"), extra = "merge") %>%
  spread(variable_name, value)
## # A tibble: 112 x 4
##
      country year fertility life_expectancy
                       <dbl>
      <chr> <chr>
## 1 Germany 1960
                        2.41
                                        69.3
## 2 Germany 1961
                                        69.8
                        2.44
## 3 Germany 1962
                        2.47
                                        70.0
## 4 Germany 1963
                        2.49
                                        70.1
## 5 Germany 1964
                        2.49
                                        70.7
## 6 Germany 1965
                        2.48
                                        70.6
## 7 Germany 1966
                        2.44
                                        70.8
## 8 Germany 1967
                        2.37
                                        71.0
## 9 Germany 1968
                        2.28
                                        70.6
## 10 Germany 1969
                        2.17
                                        70.5
## # ... with 102 more rows
```

A veces queremos hacer lo contrario: juntar dos columnas en una.

```
dat %>%
  separate(key, c("year", "first_variable_name", "second_variable_name"), fill = "right")
## # A tibble: 224 x 5
##
      country
                  year first_variable_name second_variable_name value
##
      <chr>
                  <chr> <chr>
                                            <chr>
                                                                  <dbl>
                                            <NA>
                                                                   2.41
##
   1 Germany
                  1960 fertility
## 2 South Korea 1960
                                            <NA>
                                                                   6.16
                        fertility
## 3 Germany
                  1960
                        life
                                            expectancy
                                                                  69.3
## 4 South Korea 1960
                        life
                                            expectancy
                                                                  53.0
## 5 Germany
                  1961
                        fertility
                                            <NA>
                                                                   2.44
                                            <NA>
                                                                   5.99
## 6 South Korea 1961
                       fertility
## 7 Germany
                  1961
                        life
                                            expectancy
                                                                  69.8
## 8 South Korea 1961 life
                                                                  53.8
                                            expectancy
## 9 Germany
                  1962 fertility
                                            <NA>
                                                                   2.47
## 10 South Korea 1962 fertility
                                            <NA>
                                                                   5.79
## # ... with 214 more rows
```

Llegamos a lo mismo si primero unimos la primera y segunda columna y después expandimos las columnas y renombramos fertility_NA a fertility:

```
dat %>%
  separate(key, c("year", "first_variable_name", "second_variable_name"), fill = "right") %>%
  unite(variable_name, first_variable_name, second_variable_name, sep="_") %>%
  spread(variable_name, value) %>%
  rename(fertility = fertility_NA)
```

```
## # A tibble: 112 x 4
##
      country year fertility life expectancy
##
      <chr>
              <chr>>
                         <dbl>
                                         <dbl>
##
   1 Germany 1960
                         2.41
                                          69.3
## 2 Germany 1961
                         2.44
                                          69.8
## 3 Germany 1962
                         2.47
                                          70.0
                                          70.1
## 4 Germany 1963
                         2.49
## 5 Germany 1964
                         2.49
                                          70.7
## 6 Germany 1965
                         2.48
                                          70.6
## 7 Germany 1966
                         2.44
                                          70.8
                                          71.0
## 8 Germany 1967
                         2.37
## 9 Germany 1968
                         2.28
                                          70.6
                                          70.5
## 10 Germany 1969
                         2.17
## # ... with 102 more rows
```

Ejercicios: tidy/wide

1. Niveles de CO2.

Definimos los datos de CO2 en formato wide:

```
#? co2
co2_wide <- data.frame(matrix(co2, ncol = 12, byrow = TRUE)) %>%
setNames(1:12) %>%
mutate(year = as.character(1959:1997))
```

Utiliza la función gather para reordenar este objeto en formato *tidy*. Llama CO2 a la columna con las mediciones de co2 y mes a la columna de los meses. El objeto se llamará co2_tidy.

No es capaz de hacer el plot porque month no es un numérico. Rehaz el objeto asegurandote de que month es numérico.

Que nos dice este plot?

- A. Los niveles de CO2 aumentan monotonicamente de 1959 a 1997.
- B. Los niveles de CO2 son mas altos en verano y la media anual aumento de 1959 a 1997.
- C. Los niveles de CO2 son constantes y variabilidad aleatoria es lo que explica las diferencias.
- D. Los niveles de CO2 no tienen una tendencia estacional.
 - 2. Porcentaje de admision de hombres y mujeres Utilizando los datos del paquete dslabs:

admissions

##		${\tt major}$	gender	admitted	applicants
##	1	Α	men	62	825
##	2	В	men	63	560
##	3	C	men	37	325
##	4	D	men	33	417
##	5	E	men	28	191
##	6	F	men	6	373
##	7	Α	women	82	108
##	8	В	women	68	25
##	9	C	women	34	593
##	10	D	women	35	375
##	11	E	women	24	393
##	12	F	women	7	341

- Transformalo en tidy usando spread, una fila para cada major.
- Usa gather para crear un tmp data.frame con una columna que contenga el tipo de información (aplicant/admitted).
- Usa unite para crear la column_name i que contenga la informacion de admitted_men, admitted_women, applicants_men and applicants_women
- Usa spread para generar los datos tidy con cuatro variables para cada major
- Usa %>% para escribir una sola linea de codigo que convierta admissions en la tabla tidy final.
- 3. Tibble family: convierte los datos en tidy

```
family <- tribble(
  "family, "dob_child1, "dob_child2, "gender_child1, "gender_child2,
       1L, "1998-11-26", "2000-01-29",
                                                     1L,
       2L, "1996-06-22",
                                                     2L,
                                                                      NA,
       3L, "2002-07-11", "2004-04-05",
                                                     2L,
                                                                      2L,
       4L, "2004-10-10", "2009-08-27",
                                                     1L,
                                                                      1L,
       5L, "2000-12-05", "2005-02-28",
                                                     2L.
                                                                      1L,
)
family
```

```
## # A tibble: 5 x 5
##
     family dob_child1 dob_child2 gender_child1 gender_child2
      <int> <chr>
                        <chr>
                                            <int>
##
          1 1998-11-26 2000-01-29
                                                              2
## 1
                                                1
          2 1996-06-22 <NA>
                                                2
                                                             NA
## 2
          3 2002-07-11 2004-04-05
                                                2
                                                              2
## 3
## 4
          4 2004-10-10 2009-08-27
                                                1
                                                              1
```

```
## 5
          5 2000-12-05 2005-02-28
family <- family %>% mutate_at(vars(starts_with("dob")), parse_date)
family
## # A tibble: 5 x 5
     family dob_child1 dob_child2 gender_child1 gender_child2
##
      <int> <date>
                        <date>
                                           <int>
## 1
          1 1998-11-26 2000-01-29
                                               1
                                                              2
## 2
          2 1996-06-22 NA
                                               2
                                                             NA
                                               2
                                                              2
## 3
          3 2002-07-11 2004-04-05
## 4
          4 2004-10-10 2009-08-27
                                               1
                                                              1
## 5
          5 2000-12-05 2005-02-28
                                               2
                                                              1
## # A tibble: 9 x 4
##
     family child dob
                               gender
##
      <int> <chr> <date>
                                <int>
## 1
          1 child1 1998-11-26
                                    1
## 2
          1 child2 2000-01-29
                                    2
## 3
          2 child1 1996-06-22
                                    2
          3 child1 2002-07-11
          3 child2 2004-04-05
                                    2
## 5
## 6
          4 child1 2004-10-10
                                    1
## 7
          4 child2 2009-08-27
                                    1
## 8
          5 child1 2000-12-05
                                    2
## 9
          5 child2 2005-02-28
                                    1
```

Sumarizando data con dplyr()

summarize()

\$ sex

Vamos a utilizar los datos de alturas del paquete dslabs

\$ height: num 75 70 68 74 61 65 66 62 66 67 ...

```
library(dslabs)
data(heights)
head(heights)
##
        sex height
## 1
       Male
                75
## 2
       Male
                 70
## 3
       Male
                68
## 4
       Male
                74
## 5
       Male
                61
## 6 Female
str(heights)
                     1050 obs. of 2 variables:
## 'data.frame':
```

La función summarize() del paquete dplyr nos calcula cualquier agregado que le pidamos de un vector de un data.frame o de un tibble. Como el input era un data.frame() el output también lo es.

: Factor w/ 2 levels "Female", "Male": 2 2 2 2 2 1 1 1 1 2 ...

```
heights %>%
  filter(sex == "Female") %>%
  summarize(
    average = mean(height),
```

```
standard_deviation = sd(height)
##
      average standard_deviation
## 1 64.93942
                        3.760656
Se pueden utilizar medidas mas robustas:
s <- heights %>%
  summarize(
    median = median(height),
    mad=mad(height),
    min=min(height),
    max=max(height))
s
##
    median
               mad min
       68.5 3.7065 50 82.67717
## 1
str(s)
## 'data.frame': 1 obs. of 4 variables:
## $ median: num 68.5
## $ mad : num 3.71
## $ min
          : num 50
          : num 82.7
## $ max
NOTA: con la función summarize solo podemos llamar funciones que devuelvan un solo valor.
```

dot

Recordemos en el último ejercicio de la sesión II habiamos descargado la tabla con el rate de asesinatos en todo el mundo.

```
url="https://en.wikipedia.org/wiki/List_of_countries_by_intentional_homicide_rate"
h <- read_html(url)
class(h)
## [1] "xml_document" "xml_node"
## {html_document}
## <html class="client-nojs" lang="en" dir="ltr">
## [1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset= ...
## [2] <body class="mediawiki ltr sitedir-ltr mw-hide-empty-elt ns-0 ns-sub ...
tab <- h %>% html_nodes("table")
tab <- tab[[4]] %>% html_table
head(tab)
     Country (or dependent territory, subnational area, etc.) Region
##
## 1
                                                      Burundi Africa
## 2
                                                      Comoros Africa
## 3
                                                     Djibouti Africa
## 4
                                                      Eritrea Africa
## 5
                                                     Ethiopia Africa
## 6
                                                        Kenya Africa
          Subregion Rate Count Yearlisted
                                                 Source
## 1 Eastern Africa 6.02
                                                CTS/SDG
                                     2016
                           635
```

```
## 2 Eastern Africa 7.70
                              60
                                       2015 WHO Estimate
## 3 Eastern Africa 6.48
                                       2015 WHO Estimate
                              60
## 4 Eastern Africa 8.04
                             390
                                       2015 WHO Estimate
## 5 Eastern Africa 7.56 7,552
                                       2015 WHO Estimate
## 6 Eastern Africa 5.00 2,466
                                       2017
                                                      CTS
class(tab)
## [1] "data.frame"
tab <- tab %>%
  select(starts_with("Country"),
         Region,Count,Rate,starts_with("Year")) %>%
  setNames(c("country", "continent", "total", "murder_rate", "year"))
head(tab)
##
      country continent total murder_rate year
## 1
                                       6.02 2016
      Burundi
                 Africa 635
## 2 Comoros
                  Africa
                            60
                                       7.70 2015
## 3 Djibouti
                            60
                 Africa
                                       6.48 2015
## 4 Eritrea
                  Africa
                           390
                                       8.04 2015
                  Africa 7,552
## 5 Ethiopia
                                       7.56 2015
## 6
        Kenya
                  Africa 2,466
                                       5.00 2017
Para comparar USA (nuestros datos por estados en murders) necesitabamos primero hacer la media de todos
los estados, calculando el ratio de asesinatos por 100.000 habitantes:
s <- murders %>%
  mutate(rate=total/population*100000) %>%
  summarize(mean(rate))
     mean(rate)
## 1
       2.779125
str(s)
## 'data.frame':
                     1 obs. of 1 variable:
## $ mean(rate): num 2.78
Como las funciones de dplyr devuelven el mismo tipo de objeto que su input en este caso queremos acceder
sólo al valor que tienen almacenado. Podemos hacerlo asi:
##
     mean(rate)
## 1
       2.779125
s %>% .$rate
## NULL
"." simplemente reemplaza al objeto que pasamos por el pipe, en este caso s que es n data frame. Por eso
accedemos su información con $
s <- murders %>%
  summarize(rate=mean(total/population*100000)) %>%
```

[1] 2.779125

```
s2<-murders %>%
  summarize(total=sum(total)) %>%
  .$total
group_by()
Construimos un objeto que contenga la información que teniamos de USA en el objeto tab, quedandonos solo
con medidas del año 2015:
tab.USA<-tab %>%
  filter(year=="2015") %>%
  select(-year) %>%
  add_row(country = "USA",
          continent = "Americas",
          total = s2,
          murder_rate=s)
tab.USA %>%
  group_by(continent) %>%
  summarize(mean.rate=mean(murder rate)) %>%
                                                   arrange(desc(mean.rate))
## # A tibble: 5 x 2
##
     continent mean.rate
##
     <chr>>
                  <dbl>
## 1 Americas
                  14.3
## 2 Africa
                   8.55
                   3.51
## 3 Asia
## 4 Oceania
                   3.4
## 5 Europe
                   0.235
tab.USA %>% filter(continent=="Americas") %>% arrange(murder_rate)
##
                 country continent total murder_rate
## 1
                          Americas 9403
                                              2.779125
## 2
                                      617
                                              9.290000
                Paraguay
                           Americas
## 3 Trinidad and Tobago Americas
                                      420
                                             30.880000
Ordenar data.frames: arrange() top_n()
¿Cual es el estado con mayor poblacion? La función arrange() ordena tablas enteras por una variable
murders %>% arrange(population) %>% head()
##
                    state abb
                                      region population total
## 1
                  Wyoming WY
                                        West
                                                  563626
                                                             5
                                                            99
## 2 District of Columbia DC
                                       South
                                                  601723
                  Vermont VT
                                   Northeast
                                                  625741
                                                             2
## 4
             North Dakota ND North Central
                                                  672591
                                                             4
## 5
                                                            19
                    Alaska AK
                                        West
                                                  710231
## 6
             South Dakota SD North Central
                                                  814180
                                                             8
¿Y con menor numero de asesinatos?
```

```
## state abb region population total
## 1 Vermont VT Northeast 625741 2
## 2 North Dakota ND North Central 672591 4
```

murders %>% arrange(total) %>% head()

```
## 3 New Hampshire
                             Northeast
                                           1316470
                                                        5
                     NH
## 4
                                                        5
                     WY
                                  West
                                            563626
           Wyoming
## 5
            Hawaii
                     ΗI
                                  West
                                           1360301
                                                        7
## 6
      South Dakota
                     SD North Central
                                            814180
                                                        8
```

¿Y en por cien mil habitantes?

```
murders %>% mutate(rate=total/population*100000)%>%
    arrange(rate) %>%
    head()
```

```
##
                               region population total
             state abb
                                                              rate
## 1
           Vermont
                     VT
                            Northeast
                                           625741
                                                       2 0.3196211
                            Northeast
## 2 New Hampshire
                                          1316470
                                                       5 0.3798036
## 3
            Hawaii
                     ΗI
                                  West
                                          1360301
                                                       7 0.5145920
## 4
      North Dakota
                     ND North Central
                                           672591
                                                       4 0.5947151
## 5
              Iowa
                     IA North Central
                                          3046355
                                                      21 0.6893484
## 6
             Idaho
                                                      12 0.7655102
                     ID
                                  West
                                          1567582
```

Si tenemos empates podemos usar una segunda columna para deshacer dicho empate:

```
murders %>% mutate(rate=total/population*100000)%>%
    arrange(total,rate) %>%
    head()
```

```
##
             state abb
                                region population total
                                                              rate
## 1
           Vermont
                     VT
                                                       2 0.3196211
                            Northeast
                                           625741
##
      North Dakota
                     ND North Central
                                           672591
                                                       4 0.5947151
## 3 New Hampshire
                     NH
                            Northeast
                                          1316470
                                                       5 0.3798036
## 4
                                           563626
                                                       5 0.8871131
           Wyoming
                     WY
                                  West
                                                       7 0.5145920
## 5
            Hawaii
                                          1360301
                     HI
                                  West
      South Dakota SD North Central
                                           814180
                                                       8 0.9825837
```

¿Y el mayor? Por último podemos seleccionar las primeras filas de un data.frame o de un tibble usando la función $top_n()$. Nota que la función desc() indica que se ordena de manera descendente el data.frame.

```
murders %>% mutate(rate=total/population*100000)%>%
    arrange(desc(rate)) %>%
    top_n(10)
```

Selecting by rate

##		state	abb		region	population	total	rate
##	1	District of Columbia	DC		South	601723	99	16.452753
##	2	Louisiana	LA		South	4533372	351	7.742581
##	3	Missouri	MO	${\tt North}$	${\tt Central}$	5988927	321	5.359892
##	4	Maryland	MD		South	5773552	293	5.074866
##	5	South Carolina	SC		South	4625364	207	4.475323
##	6	Delaware	DE		South	897934	38	4.231937
##	7	Michigan	MI	North	${\tt Central}$	9883640	413	4.178622
##	8	Mississippi	MS		South	2967297	120	4.044085
##	9	Georgia	GA		South	9920000	376	3.790323
##	10	Arizona	ΑZ		West	6392017	232	3.629527

Ejercicios: NCHS Data

El National Center for Health Statistics ha realizado encuestas de habitos de vida y salud desde 1960. Desde 1999 5000 individuos han sido entrevistados cada año junto con una exploración medica. Parte de estos datos están en el paquete **NHANES**

```
library(NHANES)
data(NHANES)
```

Los datos en el paquete **NHANES** contienen una gran cantidad de valores perdidos. Las principales funciones de sumarización de R devuelven un NA si hay NA en los datos.

```
data(na_example)
mean(na_example)

## [1] NA

sd(na_example)
```

```
## [1] NA
```

[1] 1.22338

Para ignorar los valores perdidos usamos el argumento na.rm:

```
mean(na_example, na.rm = TRUE)

## [1] 2.301754

sd(na_example, na.rm = TRUE)
```

Vamos a explorar los datos en **NHANES**

1. Tensión sanguínea: Seleccionemos a las mujeres entre 20 y 29 años. AgeDecade es una variable categórica que contiene las edades. La categoría es " 20-29", con un espacio delante! Cual es su media? (BPSysAve variable). Guardalo en una variable llamadaref.

Hint: Usa filter y summarize y luego usa na.rm = TRUE al calcular su meda y desviacion estandard. Tambien podrias quitar los missing usando filter.

- 2. Usando pipe asigna ese valor a una variable llamada ref_avg. Hint: Use the code similar to above and then pull.
- 3. min y max para cada grupo de edad dentro de las mujeres
- 4. Media y desviacion estandar para cada grupo de edad. Hint: filtra por genero y luego usa group_by.
- 5. Hacer lo mismo para los hombres
- 6. Usando group_by(AgeDecade, Gender), repite 4 y 5 con una sola linea de código.
- 7. Para los hombres entre 40-49 compara su presion sistolica para las distintas razas reportadas en la variable Race1 y ordenalas de mayor a menor.

Tidyverse conditionals

case_when

```
## [1] "Negative" "Negative" "Zero" "Positive" "Positive"
```

Imaginemos que queremos comparar los rates de asesinatos en tres regiones: New England, West Coast, South, y other. Para cada estado necesitamos preguntar si es de cada uno de ellos y si no pasar al siguiente:

```
data(murders)
murders %>%
  mutate(group = case_when(
    abb %in% c("ME", "NH", "VT", "MA", "RI", "CT") ~ "New England",
    abb %in% c("WA", "OR", "CA") ~ "West Coast",
    region == "South" ~ "South",
   TRUE ~ "other")) %>%
  group_by(group) %>%
  summarize(rate = sum(total) / sum(population) * 10^5) %>%
  arrange(rate)
## # A tibble: 4 x 2
##
     group
                  rate
##
     <chr>>
                 <dbl>
## 1 New England 1.72
## 2 other
                  2.71
## 3 West Coast
                  2.90
## 4 South
                  3.63
between
x >= a & x <= b
Utilizando tidvverse:
between(x, a, b)
```

Limpieza de datos: el paquete janitor

tabyl better than table: adorn_() functions

tabyl es la alternativa en el universo tidyverse a table. Es un tipo de objeto que vais a usar mucho como data scientists. Cuenta combinaciones de 1,2,3 variables de una forma mas eficiente que table. Una vez creada la tabla podemos formatearla como queramos usando adorn_* functions

Problemas de table:

- No acepta data.
frame inputs y no combina bien con %>%
- No produce data.frames

• Su resultado es dificil de formatear

tabyl() que forma parte del paquete janitor soluciona estos problemas. Ademas funciona con vectores y no cuenta los NAs.

```
x <- c("big", "big", "small", "small", "small", NA)
tabyl(x)
##
              percent valid_percent
        x n
##
      big 2 0.3333333
                                0.4
    small 3 0.5000000
##
                                0.6
     <NA> 1 0.1666667
                                 NA
Ejemplo 1: mtcars
mtcars %>%
  tabyl(gear, cyl) %>%
  adorn_totals("col") %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(digits = 2) %>%
  adorn_ns() %>%
  adorn_title()
##
                cyl
##
    gear
                  4
                             6
                                         8
                                                   Total
       3 6.67% (1) 13.33% (2) 80.00% (12) 100.00% (15)
       4 66.67% (8) 33.33% (4) 0.00% (0) 100.00% (12)
##
       5 40.00% (2) 20.00% (1) 40.00% (2) 100.00% (5)
adorn() se puede llamar en todo tipo de objetos, no solo en un tabyl()
mtcars %>% adorn_totals("col") %>% adorn_percentages("col") %>% head()
##
    mpg
                cyl
                          disp
                                       hp
                                                 drat
##
   21.0 0.03030303 0.02167111 0.02343417 0.03388652 0.02544875 0.02881854
## 21.0 0.03030303 0.02167111 0.02343417 0.03388652 0.02792564 0.02979901
## 22.8 0.02020202 0.01462800 0.01981253 0.03345208 0.02253477 0.03258281
##
   21.4 0.03030303 0.03494467 0.02343417 0.02676166 0.03122815 0.03403600
   18.7 0.04040404 0.04876001 0.03728164 0.02736988 0.03341363 0.02979901
##
##
  18.1 0.03030303 0.03047500 0.02236898 0.02398123 0.03360789 0.03540164
##
                                gear
                                            carb
                                                      Total
            VS
                       am
## 0.00000000 0.07692308 0.03389831 0.04444444 0.02315761
## 0.00000000 0.07692308 0.03389831 0.04444444 0.02321889
## 0.07142857 0.07692308 0.03389831 0.01111111 0.01780394
## 0.07142857 0.00000000 0.02542373 0.01111111 0.03043280
   0.00000000 0.00000000 0.02542373 0.02222222 0.04298045
```

Ejemplo 2: starwars

```
humans <- starwars %>%
  filter(species == "Human")

t1 <- humans %>%
  tabyl(eye_color)
```

0.07142857 0.00000000 0.02542373 0.01111111 0.02762852

```
t1 %>%
  adorn_totals("row") %>%
  adorn_pct_formatting()
   eye_color n percent
##
         blue 12
                   34.3%
##
   blue-gray 1
                    2.9%
##
       brown 17
                   48.6%
##
        dark 1
                   2.9%
                    5.7%
##
       hazel 2
##
       yellow 2
                    5.7%
##
       Total 35 100.0%
Se pueden ademas producir tablas de contingencia con tabyl
t2 <- humans %>%
  tabyl(gender, eye_color)
t2 %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(digits = 2) %>%
  adorn_ns()
## gender
                 blue blue-gray
                                      brown
                                                 dark
                                                           hazel
                                                                    yellow
## female 33.33% (3) 0.00% (0) 55.56% (5) 0.00% (0) 11.11% (1) 0.00% (0)
      male 34.62% (9) 3.85% (1) 46.15% (12) 3.85% (1) 3.85% (1) 7.69% (2)
Tablas con 3 variables tabyl
t3 <- humans %>%
  tabyl(eye_color, skin_color, gender)
humans %>%
  tabyl(eye_color, skin_color, gender, show_missing_levels = FALSE) %>%
  adorn_totals("row") %>%
  adorn_percentages("all") %>%
  adorn pct formatting(digits = 1) %>%
  adorn_ns %>%
  adorn_title
## $female
##
              skin_color
##
    eye_color
                    fair
                             light
##
        blue 22.2% (2) 11.1% (1)
        brown 11.1% (1) 44.4% (4)
##
##
               0.0% (0) 11.1% (1)
        hazel
        Total 33.3% (3) 66.7% (6)
##
##
## $male
##
              skin color
##
                                        light
    eye_color
                   dark
                               fair
                                                  pale
                                                            tan
                                                                   white
              0.0% (0) 26.9% (7) 7.7% (2) 0.0% (0) 0.0% (0) 0.0% (0)
##
        blue
                               (1) 0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
##
    blue-gray
               0.0% (0) 3.8%
##
        brown 11.5% (3) 15.4% (4) 11.5% (3) 0.0% (0) 7.7% (2) 0.0% (0)
              3.8% (1) 0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
##
        dark
##
              0.0% (0) 3.8% (1) 0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
       hazel
```

```
## yellow 0.0% (0) 0.0% (0) 0.0% (0) 3.8% (1) 0.0% (0) 3.8% (1) 
## Total 15.4% (4) 50.0% (13) 19.2% (5) 3.8% (1) 7.7% (2) 3.8% (1)
```

Se pueden presentar tablas de manera incluso mas elegante usando kable del paquete knitr

```
humans %>%
  tabyl(gender, eye_color) %>%
  adorn_totals(c("row", "col")) %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(rounding = "half up", digits = 0) %>%
  adorn_ns() %>%
  adorn_title("combined") %>%
  knitr::kable()
```

gender/eye_color	blue	blue-gray	brown	dark	hazel	yellow	Total
female	33% (3)	0% (0)	56% (5)	0% (0)	11% (1)	0% (0)	100% (9)
male	35% (9)	4% (1)	46% (12)	4% (1)	4% (1)	8% (2)	100% (26)
Total	34% (12)	3% (1)	49% (17)	3% (1)	6% (2)	6% (2)	100% (35)

Ejemplo 3: Modelos de coches

```
mpg_by_cyl_and_am <- mtcars %>%
  group_by(cyl, am) %>%
  summarise(mpg = mean(mpg)) %>%
  spread(am, mpg)
mpg_by_cyl_and_am
## # A tibble: 3 x 3
## # Groups: cyl [3]
            .0,
##
       cyl
                   11
##
     <dbl> <dbl> <dbl>
## 1
        4 22.9 28.1
## 2
         6 19.1 20.6
## 3
        8 15.0 15.4
mpg_by_cyl_and_am %>%
  adorn_rounding() %>%
  adorn ns(
   ns = mtcars %% # calculate the Ns on the fly by calling tabyl on the original data
      tabyl(cyl, am)
  adorn_title("combined", row_name = "Cylinders", col_name = "Is Automatic")
##
   Cylinders/Is Automatic
                                    0
## 1
                          4 22.9 (3) 28.1 (8)
## 2
                          6 19.1 (4) 20.6 (3)
## 3
                          8 15.1 (12) 15.4 (2)
```

Otras funciones del paquete janitor

```
get_dupes()
```

```
get_dupes(mtcars, wt, cyl)
```

```
## # A tibble: 4 x 12
##
                    wt cyl dupe_count mpg disp
                                                                                                                 hp drat qsec
                                                                                                                                                                 vs
                                                                                                                                                                                  am gear
##
             <dbl> 
## 1 3.44
                                                                    2 19.2 168.
                                                                                                               123 3.92 18.3
                                                                                                                                                                 1
                                                                                                                                                                                  0
                               6
                                                                                                               123 3.92 18.9
## 2 3.44
                                     6
                                                                    2 17.8 168.
                                                                                                                                                                                    0
## 3 3.57
                                                                                                               245 3.21 15.8
                                   8
                                                                    2 14.3 360
                                                                                                                                                                 0
                                                                                                                                                                                    0
                                                                                                                                                                                                    3
## 4 3.57
                                    8
                                                                    2 15
                                                                                             301
                                                                                                               335 3.54 14.6
## # ... with 1 more variable: carb <dbl>
get_dupes()
# remove empty() rows and columns
q \leftarrow data.frame(v1 = c(1, NA, 3),
                                          v2 = c(NA, NA, NA),
                                          v3 = c("a", NA, "b"))
q %>%
    remove empty(c("rows", "cols"))
##
         v1 v3
## 1 1 a
## 3 3 b
round_half_up()
nums \leftarrow c(2.5, 3.5)
round(nums)
## [1] 2 4
round half up(nums)
## [1] 3 4
factores
# Count factor levels in groups of high, medium, and low with top_levels()
f <- factor(</pre>
    c("strongly agree", "agree", "neutral", "neutral", "disagree", "strongly agree"),
    levels = c("strongly agree", "agree", "neutral", "disagree", "strongly disagree"))
top_levels(f)
##
                                                                                               percent
                                                                               f n
##
                           strongly agree, agree 3 0.5000000
##
                                                               neutral 2 0.3333333
## disagree, strongly disagree 1 0.1666667
top_levels(f, n = 1)
##
                                                                       f n
                                                                                       percent
##
                                     strongly agree 2 0.3333333
          agree, neutral, disagree 4 0.6666667
                             strongly disagree 0 0.0000000
##
```